

Physics-Informed Runtime Safety per Controller Data-Driven

Dal "GP-wrapper" all'Adaptive Safety Envelope

L'idea in una riga

Un controller **data-driven** addestrato su una distribuzione **crolla quando il sistema deriva fuori distribuzione**.

Gli affianchiamo un **layer di sicurezza fisico** che subentra quando il sistema viola la SLA.

Lo chiamiamo Adaptive Safety Envelope — non "safe-RL", ma un pattern architetturale generale


Il problema è reale

PPO addestrato su carico pulito:

- ✓
 - **0%** violazioni in distribuzione
- ✗
 - **23%** violazioni quando il service-time cambia (drift)

La policy congelata **non vede** il drift e satura sotto il massimo dei core.

Questa è la motivazione dell'**Adaptive Safety Envelope**.




Lo shift di paradigma

	PRIMA · GPPPO	DOPO · Adaptive Safety Envelope
Guardrail	Gaussian Process	Modello fisico + PI
Cosa fa	corregge il PI (circolare)	stima $\mu^{\wedge}$ online , azione in forma chiusa
Trigger	incertezza GP (fragile)	violazione SLA osservabile
Generalità	legato a PPO	policy-agnostic, multi-dominio

Il GP era circolare, fragile *proprio sotto drift*, senza prior fisico. Il floor fisico dà una **garanzia provabile**.

Adaptive Safety Envelope — il contributo

Adaptive Safety Envelope — un pattern, layer fisici swappabili




3 layer **swappabili** (domain-specific) + 2 **generali** (PI + FSM) → nuovo dominio = cambi solo le scatole fisiche.

Generalità: stessa ricetta, 4 domini

Dominio	ProcessID (μ)	Physical Model	PI su
Autoscaling	Utilization Law	M/M/c + Erlang-C	errore RT
HVAC	parametri termici RC	eq. calore 1-zona	temperatura
Cruise Control	massa + drag	dinamica longitud.	velocità
Grid	inerzia equivalente	swing equation	Δf

L'Adaptive Safety Envelope non cambia. Cambiano solo le due scatole fisiche (domain-specific) → è un *pattern*, non un sistema.

I risultati locali



Handover e **MMC-PI** = istanze dell'**Adaptive Safety Envelope** per l'autoscaling.

Scenario fair e appaiato: lam=30, drift ramp t=300→600, SLA=0.25s, stesso seed.

I numeri

Controller	Viol. SLA	RT p95	Costo (cores)
PPO-only (nudo)	7.8 %	0.270 s	3.10
HandoverPPO (PPO + safety)	0.8 %	0.212 s	3.36
MMC-PI (solo fisica)	0.0 %	0.203 s	3.72

- L'**Adaptive Safety Envelope** azzerà quasi le violazioni con **+8–20% di costo**
- La fisica da sola è già al sicuro → è lei il motore della safety

Stato — onesto

 Funziona	 Da fare per il paper
Tesi: data-driven crolla, fisica recupera	Multi-seed (oggi seed singolo)
Floor M/M/c → garanzia provabile	Ablation formale a 4 vie
FSM handover stabile (isteresi)	Risultati AWS del nuovo sistema
	2° dominio

Limite onesto: a drift severo nessuno recupera (saturazione) → è un *envelope di recuperabilità*.


Discussione

1. **Quale 2° dominio?** → HVAC (simulatori pronti) vs Cruise Control (più "AV")
2. **Garanzia da rivendicare?** → deterministica (floor M/M/c) vs probabilistica
3. **Posizionamento?** → venue SE (SEAMS/ICSE) vs systems (NSDI/ATC)
4. **Attacco reviewer** → "reattivo, non predittivo": il trigger osservabile è *più affidabile* di una stima d'incertezza

Posizionamento nella letteratura

dove ci collochiamo · radici teoriche · lavori più vicini

Dove si colloca



Intersezione di più comunità SE — la radice teorica (in **rosso**) è la *Simplex architecture* del controllo.

Radici nella teoria del controllo

Nostro componente	Concetto di controllo	Riferimento seminale
RL + controller sicuro + switch	Simplex Architecture	Sha, <i>IEEE Software</i> 2001
Safety ctrl = online ID + M/M/c	Self-Tuning Regulator (adattivo)	Åström & Wittenmark
FSM con isteresi + dwell	Supervisory switched control / dwell-time	Liberzon 2003 · Hespanha–Morse 1999
Transizione senza salti	Bumpless transfer + anti-windup	Åström & Hägglund
(cugino continuo)	Safety filter / Control Barrier Function	Ames TAC 2017 · Wabersich–Zeilinger 2021

È una **Simplex architecture data-driven** — ma il controller sicuro è **adattivo** (costruito online), non fisso/pre-certificato. Questo è il delta control-theory.

I filoni SE a cui ci agganciamo

Filone	Ancora	Il nostro aggancio / gap
Control Theory for SE	Filieri ICSE'14 · Shevtsov TSE'17	casa naturale; lì il controller è il PI — noi: PI come guardrail di un RL
Safe-RL / Shielding	Alshiekh AAAI'18 · SMARLA TSE'24	shield physics-based , non da automa formale
Models@runtime	Blair'09 · Gandhi DC2 ICAC'14	modello fisico vivo via online process-ID
SE4AI / Concept Drift	Pham ICSE'24 · Paleyes CSUR'22	da <i>detect-then-retrain</i> a mitigation runtime

Lavori più vicini → il nostro delta

Lavoro vicino	Cosa fa	Cosa abbiamo in più
Neural Simplex (NFM'20)	RL + safe baseline + switch	baseline costruito online (ID+M/M/c), non pre-certificato
SafeSlice (2025)	RL + override SLA-aware (slicing)	dominio autoscaling + modello fisico, non filtro di costo
Gandhi DC2 (ICAC'14)	queueing+Kalman per autoscaling	è guardrail di un RL , non controller standalone
Sinha-Pavone (CDC'23)	OOD monitor → fallback MPC	anchor PI leggero , framing SE/drift

Novelty **media** → **forte se riposizionata**: non "switch RL→safe" (è Simplex), ma "**safety controller adattivo physics-informed** costruito a runtime, dove non esiste un baseline pre-verificato".

Come ci vendiamo + venue

Claim (1 frase): l'**Adaptive Safety Envelope** è una *Simplex architecture* in cui il controller ad alta affidabilità non è fisso ma un **self-tuning regulator** guidato da identificazione online + modello **M/M/c in forma chiusa**; handover via **supervisore a isteresi/dwell**.

- **Venue casa:** SEAMS (self-adaptive + assurance) → poi **ICSE / FSE / TSE**
- **Framing:** self-adaptive systems, *non* safe-RL
- **Da blindare:** ricerca mirata "Simplex + autoscaling" (punto cieco); differenziare da SafeSlice e Neural Simplex